



TECNOLÓGICO  
NACIONAL DE MÉXICO



# ANÁLISIS DE PREDICCIÓN DE EPISODIOS DE MALA CALIDAD DEL AIRE EN MÉXICO

Dashboard Interactivo con Machine Learning

**Proyecto Final — 1er Departamental**



**Alumna:**  
**Ariadna PPerez Blancarte**  
**Grupo:**  
**15801**

# **PREDICCIÓN DE EPISODIOS DE MALA CALIDAD DEL AIRE EN MÉXICO MEDIANTE TÉCNICAS DE MACHINE LEARNING**

## **INTRODUCCIÓN**

La contaminación atmosférica constituye uno de los principales desafíos ambientales y de salud pública a nivel mundial. La exposición prolongada a contaminantes presentes en el aire, particularmente a las partículas suspendidas PM2.5, se encuentra asociada con enfermedades respiratorias, cardiovasculares y diversos efectos adversos sobre la calidad de vida de la población.

En México, y particularmente en la Zona Metropolitana del Valle de México, las condiciones geográficas, la alta densidad poblacional, el crecimiento urbano y el incremento constante del parque vehicular favorecen la acumulación de contaminantes atmosféricos. Como consecuencia, la vigilancia y predicción de la calidad del aire se ha convertido en una actividad estratégica para la implementación de políticas públicas orientadas a la protección de la salud y el medio ambiente.

En los últimos años, el desarrollo de técnicas de Ciencia de Datos y Aprendizaje Automático ha permitido construir modelos predictivos capaces de identificar patrones complejos dentro de grandes volúmenes de información ambiental. Estas técnicas ofrecen herramientas que facilitan la anticipación de eventos de contaminación y la generación de alertas tempranas para la población.

El presente proyecto tiene como finalidad desarrollar un sistema de predicción de episodios de mala calidad del aire utilizando información histórica proveniente del Sistema Nacional de Información de la Calidad del Aire (SINAICA). Para ello se integraron variables relacionadas con la concentración de partículas PM2.5 y diversos factores meteorológicos, incluyendo temperatura, humedad relativa, velocidad del viento y presión atmosférica. Posteriormente, se aplicaron diferentes algoritmos de clasificación con el propósito de identificar las condiciones ambientales asociadas a escenarios de riesgo.

## **PLANTEAMIENTO DEL PROBLEMA**

La calidad del aire en las grandes ciudades presenta variaciones significativas debido a la interacción de factores meteorológicos, geográficos y antropogénicos. La identificación temprana de condiciones que favorecen la acumulación de contaminantes representa una herramienta fundamental para la toma de decisiones en materia ambiental y sanitaria.

Sin embargo, los métodos tradicionales de monitoreo suelen enfocarse únicamente en la observación de las concentraciones actuales de contaminantes, limitando la capacidad de anticipar episodios futuros de deterioro ambiental. En este contexto surge la necesidad de implementar modelos predictivos que permitan estimar de manera anticipada la ocurrencia de condiciones de mala calidad del aire utilizando información histórica y variables meteorológicas relacionadas.

## **OBJETIVOS**

### **3.1 Objetivo General**

Desarrollar y evaluar modelos de aprendizaje automático capaces de predecir episodios de mala calidad del aire en la Ciudad de México mediante el análisis de variables ambientales y meteorológicas obtenidas del Sistema Nacional de Información de la Calidad del Aire.

### **3.2 Objetivos Específicos**

- Obtener y procesar datos históricos de calidad del aire y variables meteorológicas.
- Realizar el análisis exploratorio de los datos para identificar patrones y relaciones entre variables.
- Construir una variable objetivo que permita clasificar las condiciones ambientales.
- Implementar diferentes algoritmos de clasificación basados en aprendizaje automático.
- Comparar el desempeño de los modelos utilizando métricas de evaluación estandarizadas.
- Identificar las variables con mayor influencia sobre la calidad del aire.

## **DESCRIPCIÓN DE LOS DATOS**

La información utilizada en el presente estudio fue obtenida a partir del Sistema Nacional de Información de la Calidad del Aire (SINAICA), plataforma oficial encargada de recopilar y difundir datos ambientales provenientes de estaciones de monitoreo distribuidas en el territorio nacional.

Se seleccionaron registros correspondientes a la estación "Presidencia Municipal", considerando las siguientes variables:

| VARIABLE | DESCRIPCIÓN                                                       |
|----------|-------------------------------------------------------------------|
| PM2.5    | Concentración de partículas suspendidas menores a 2.5 micrómetros |
| TMP      | Temperatura ambiental                                             |
| HR       | Humedad relativa                                                  |
| VV       | Velocidad del viento                                              |
| PB       | Presión barométrica                                               |
| PP       | Precipitación pluvial                                             |

Los datos fueron procesados y agregados a nivel diario para facilitar su integración y posterior análisis.

| Nombre                                      | Fecha de modificación  | Tipo                 | Tamaño   |
|---------------------------------------------|------------------------|----------------------|----------|
| Hoy                                         |                        |                      |          |
| Datos SINAICA - Presidencia Municipal - ... | 17/06/2026 04:25 p. m. | Hoja de cálculo d... | 1,688 KB |
| Datos SINAICA - Presidencia Municipal - ... | 17/06/2026 04:25 p. m. | Archivo              | 2,019 KB |
| Datos SINAICA - Presidencia Municipal - ... | 17/06/2026 04:25 p. m. | Hoja de cálculo d... | 1,709 KB |
| Datos SINAICA - Presidencia Municipal - ... | 17/06/2026 04:24 p. m. | Hoja de cálculo d... | 3 KB     |
| Datos SINAICA - Presidencia Municipal - ... | 17/06/2026 04:24 p. m. | Hoja de cálculo d... | 1,988 KB |
| Datos SINAICA - Presidencia Municipal - ... | 17/06/2026 04:24 p. m. | Hoja de cálculo d... | 1,568 KB |
| Datos SINAICA - Presidencia Municipal - ... | 17/06/2026 04:24 p. m. | Hoja de cálculo d... | 2,484 KB |

## METODOLOGÍA

La metodología empleada se estructuró en cinco etapas principales:

### 1. Recolección de datos

Obtención de información histórica proveniente de SINAICA correspondiente a variables de contaminación atmosférica y condiciones meteorológicas.

### 2. Preprocesamiento

Conversión de formatos, limpieza de registros inconsistentes, tratamiento de valores faltantes y agrupación de observaciones por fecha.

### **3. Ingeniería de características**

Se generaron nuevas variables derivadas con el objetivo de incorporar información temporal relevante para la predicción:

- Concentración de PM2.5 del día anterior.
- Promedio móvil de PM2.5 considerando tres días consecutivos.

### **4. Construcción de la variable objetivo**

Con el propósito de formular un problema de clasificación binaria, se utilizó la mediana de la concentración de PM2.5 como umbral de referencia.

Las observaciones fueron clasificadas de la siguiente manera:

- Clase 0: Calidad del aire aceptable.
- Clase 1: Mala calidad del aire.

El procedimiento permitió obtener una distribución balanceada de 147 observaciones por cada categoría.

### **5. Entrenamiento y evaluación de modelos**

Se implementaron cuatro algoritmos de clasificación:

- Regresión Logística.
- Random Forest.
- Gradient Boosting.
- Red Neuronal Artificial.

## ANÁLISIS EXPLORATORIO DE DATOS

### 6.1 Distribución de PM2.5




Figura 1. Histograma de concentraciones de PM2.5

La distribución de los valores de PM2.5 presenta una concentración importante de observaciones en rangos bajos e intermedios. Se observan algunos valores extremos que representan episodios atípicos de contaminación atmosférica.

Las estadísticas descriptivas indican una concentración promedio de 13.20 µg/m³, una mediana de 11.92 µg/m³ y un valor máximo de 64.33 µg/m³.

### 6.2 Distribución de la variable objetivo





Figura 2. Distribución de clases

La variable objetivo fue construida utilizando la mediana de PM2.5 como criterio de clasificación, obteniendo una distribución perfectamente balanceada de las categorías analizadas.



**Figura 3. Distribución de la variable objetivo.**

La variable objetivo fue construida utilizando la mediana de la concentración de PM2.5 ( $11.92 \mu\text{g}/\text{m}^3$ ) como criterio de clasificación. Como resultado se obtuvo una distribución equilibrada de las categorías analizadas, con 147 observaciones clasificadas como calidad aceptable y 147 observaciones clasificadas como mala calidad del aire. Este balance favorece el entrenamiento de los modelos predictivos al evitar sesgos hacia una categoría específica.

### 6.3 Correlación entre variables

*Figura 3. Matriz de correlación*

La matriz de correlación permite identificar la relación existente entre las variables meteorológicas y los niveles de contaminación atmosférica. Este análisis constituye una herramienta fundamental para comprender la influencia relativa de cada factor dentro del fenómeno estudiado.

## RESULTADOS

### 7.1 Evaluación de Modelos

Los modelos fueron evaluados utilizando la métrica Accuracy, que mide la proporción de observaciones clasificadas correctamente respecto al total de registros analizados.




**Tabla 1. Comparación de modelos**

| <b>Modelo</b>              | <b>Accuracy</b> |
|----------------------------|-----------------|
| <b>Regresión Logística</b> | 82.95 %         |
| <b>Random Forest</b>       | 86.36 %         |
| <b>Gradient Boosting</b>   | 87.50 %         |
| <b>Red Neuronal</b>        | 80.68 %         |

**Figura 4. Comparación de Accuracy**

Los resultados muestran que el algoritmo Gradient Boosting obtuvo el mejor desempeño general, alcanzando una precisión superior al 87 %, seguido por Random Forest con un desempeño cercano al 86 %.

## 7.2 Matriz de Confusión



*Figura 5. Matriz de Confusión del modelo Random Forest*

La matriz de confusión permite evaluar detalladamente el comportamiento del modelo.

Se identificaron:

- 39 verdaderos negativos.
- 37 verdaderos positivos.
- 5 falsos positivos.
- 7 falsos negativos.

Estos resultados indican una capacidad adecuada para diferenciar entre episodios de calidad aceptable y mala calidad del aire.

### 7.3 Importancia de Variables

*Figura 6. Importancia de variables del modelo Random Forest*

El análisis de importancia de variables muestra que los indicadores históricos relacionados con PM2.5 presentan la mayor contribución dentro del proceso de clasificación. Esto confirma la relevancia de la información temporal para la predicción de condiciones ambientales futuras.

#### **DISCUSIÓN**

Los resultados obtenidos evidencian que los modelos de aprendizaje automático pueden capturar relaciones significativas entre variables meteorológicas y concentraciones de contaminantes atmosféricos.

La incorporación de variables históricas permitió mejorar la capacidad predictiva de los algoritmos, particularmente en los modelos basados en ensambles de árboles de decisión. Asimismo, la comparación de múltiples enfoques permitió identificar las fortalezas y limitaciones de cada técnica aplicada.

## CONCLUSIONES

Se desarrolló exitosamente un sistema de clasificación para la predicción de episodios de mala calidad del aire utilizando información proveniente del Sistema Nacional de Información de la Calidad del Aire.

La integración de variables meteorológicas y contaminantes atmosféricos permitió construir un conjunto de datos adecuado para la aplicación de técnicas de aprendizaje automático.

Entre los algoritmos evaluados, el modelo Gradient Boosting presentó el mejor desempeño, alcanzando una precisión de 87.50 %, seguido por Random Forest con 86.36 %. Estos resultados demuestran la capacidad de los métodos de ensamble para modelar fenómenos ambientales complejos.

Finalmente, el proyecto permitió comprobar que las técnicas de Ciencia de Datos constituyen herramientas valiosas para apoyar la gestión ambiental y la generación de sistemas de alerta temprana relacionados con la calidad del aire.

## REFERENCIAS

- *Sistema Nacional de Información de la Calidad del Aire (SINAICA).*
- *Instituto Nacional de Ecología y Cambio Climático (INECC).*
- *Pedregosa, F. et al. (2011). Scikit-learn: Machine Learning in Python. Journal of Machine Learning Research.*
- *McKinney, W. (2022). Python for Data Analysis. O'Reilly Media.*
- *Géron, A. (2022). Hands-On Machine Learning with Scikit-Learn, Keras & TensorFlow. O'Reilly Media.*
- *Documentación oficial de Pandas, Scikit-Learn, Matplotlib y Seaborn.*